

Validação do Conjunto de Dados

ECOS04 - Simulação e Avaliação de Desempenho

Edmilson Marmo Moreira
edmarmo@unifei.edu.br

Universidade Federal de Itajubá - UNIFEI
Instituto de Engenharia de Sistemas e Tecnologias da Informação - IESTI

Laboratório 3: Validação de Conjunto de Dados

Objetivos:

- analisar conjuntos de dados como realizações de variáveis aleatórias;
- verificar se dados observados são compatíveis com uma distribuição teórica;
- compreender o papel das hipóteses estatísticas (H_0 e H_1);
- aplicar testes de aderência (qui-quadrado);
- interpretar resultados sem afirmar conclusões definitivas;
- relacionar a análise de dados com a geração de números aleatórios.

Em muitos problemas práticos, tem-se acesso apenas a um conjunto de dados observados.

Surge então a seguinte questão:

Esses dados podem ter sido gerados por uma distribuição conhecida?

Essa pergunta é central em:

- modelagem de sistemas;
- simulação;
- análise de desempenho.

Validação de Dados

Exemplos típicos:

- tempos entre chegadas de clientes → distribuição exponencial?
- número de chegadas por intervalo → distribuição de Poisson?
- valores gerados por um algoritmo → distribuição uniforme?

Cada conjunto de dados pode ser interpretado como uma **realização de uma variável aleatória**.

Objetivo: verificar se os dados são compatíveis com um modelo probabilístico.

Validação de Dados

Para verificar se um conjunto de dados apresenta o comportamento esperado de uma variável aleatória, utilizam-se testes estatísticos.

Esses testes avaliam se os dados observados seguem a distribuição teórica desejada (como uniforme, exponencial, normal, entre outras) ou se há desvios significativos que indiquem inadequação do modelo.

Dentre os testes mais utilizados, destacam-se:

- **Teste do qui-quadrado** (χ^2): compara as frequências observadas com as frequências esperadas segundo uma distribuição teórica. Diferenças significativas podem indicar inadequação do modelo.
- **Teste de Kolmogorov-Smirnov**: compara a função de distribuição acumulada empírica dos dados com a função de distribuição acumulada teórica. É especialmente sensível a discrepâncias sutis, sendo indicado para distribuições contínuas.

Testes de Hipótese

Testes de Hipótese

Esses testes são baseados na formulação de duas hipóteses complementares:

- **Hipótese nula (H_0):** assume que os dados observados seguem a distribuição teórica proposta. Em outras palavras, quaisquer diferenças observadas são atribuídas ao acaso.
- **Hipótese alternativa (H_1):** assume que os dados *não* seguem a distribuição proposta. A discrepância observada é considerada grande demais para ser explicada apenas por variação aleatória.

Testes de Hipótese

Em um teste estatístico, toma-se uma decisão com base em dados observados.

- Parte-se de uma **hipótese nula** (H_0);
- Os dados são utilizados para decidir entre:
 - ▶ **não rejeitar** H_0 , ou
 - ▶ **rejeitar** H_0 .

Importante:

- Não se “prova” que H_0 é verdadeira;
- Apenas se verifica se há evidências para rejeitá-la.

Testes de Hipótese

	H_0 é verdadeira	H_0 é falsa
Não rejeitar H_0	Decisão correta	Erro Tipo II
Rejeitar H_0	Erro Tipo I	Decisão correta

- **Erro Tipo I:** rejeitar H_0 quando ela é verdadeira;
- **Erro Tipo II:** não rejeitar H_0 quando ela é falsa.

Testes de Hipótese

O objetivo de um teste de hipótese é avaliar se há evidências suficientes, nos dados observados, para rejeitar H_0 .

Para isso, calcula-se uma **estatística de teste** e a compara com um **valor crítico**, obtido da distribuição teórica apropriada (como a distribuição χ^2).

Se a estatística calculada exceder o valor crítico, para um nível de significância pré-definido (geralmente 5%), rejeita-se a hipótese nula em favor da alternativa.

Caso contrário, **não se rejeita** H_0 , o que significa apenas que os dados são compatíveis com a distribuição assumida, **não que essa seja verdadeira**.

Atividade Prática

No SIGAA, está disponível o arquivo `dados1.txt`, que contém **5 conjuntos de dados**, apresentados em sequência.

Cada conjunto é composto por valores inteiros entre **0 e 9**.

Cada grupo deverá:

- identificar e separar os conjuntos de dados;
- utilizar Python para analisar cada conjunto;
- observar a distribuição das frequências;
- decidir se a hipótese de distribuição uniforme deve ser rejeitada.

Observação: cada conjunto deve ser analisado separadamente.

Atividade Prática

Exemplo em Python:

```
import matplotlib.pyplot as plt

# Substituir pelos dados do arquivo
dados = [0, 3, 7, 2, 9, 5, 1, 8, 4, 6,
         2, 7, 0, 5, 9, 3, 6, 1, 8, 4]

# Inicializa frequencias de 0 a 9
frequencias = [0] * 10

# Conta ocorrencias
for valor in dados:
    frequencias[valor] += 1

# Exibe tabela de frequencias
for i in range(10):
    print(f"Valor {i}: {frequencias[i]}")
```

Atividade Prática

Gráfico de barras:

```
# Valores possiveis
valores = list(range(10))

# Grafico de barras
plt.bar(valores, frequencias)

plt.xlabel("Valores")
plt.ylabel("Frequencia")
plt.title("Distribuicao dos dados")

plt.show()
```

Conclusões — Conjunto 1

- Frequências aproximadamente equilibradas;
- Todos os valores aparecem;
- Não há concentração evidente.

Conclusões — Conjunto 1

- Frequências aproximadamente equilibradas;
- Todos os valores aparecem;
- Não há concentração evidente.

Conclusão: não há evidências para rejeitar H_0 .

Conclusões — Conjunto 2

- Pequeno desbalanceamento nas frequências;
- Um valor aparece mais vezes que os demais;
- Diferenças ainda relativamente pequenas.

Conclusões — Conjunto 2

- Pequeno desbalanceamento nas frequências;
- Um valor aparece mais vezes que os demais;
- Diferenças ainda relativamente pequenas.

Conclusão: não há evidências fortes para rejeitar H_0 , mas o resultado é questionável.

Conclusões — Conjunto 3

- Forte concentração em poucos valores;
- Frequências muito desiguais;
- Evidente desbalanceamento.

Conclusões — Conjunto 3

- Forte concentração em poucos valores;
- Frequências muito desiguais;
- Evidente desbalanceamento.

Conclusão: há evidências para rejeitar H_0 .

Conclusões — Conjunto 4

- Diversos valores não aparecem;
- Intervalo de possíveis valores não é coberto;
- Distribuição incompleta.

Conclusões — Conjunto 4

- Diversos valores não aparecem;
- Intervalo de possíveis valores não é coberto;
- Distribuição incompleta.

Conclusão: há evidências para rejeitar H_0 .

Conclusões — Conjunto 5

- Frequências equilibradas entre os valores;
- Aparente distribuição uniforme;
- Presença de padrão nos dados.

Conclusões — Conjunto 5

- Frequências equilibradas entre os valores;
- Aparente distribuição uniforme;
- Presença de padrão nos dados.

Conclusão: não há evidências para rejeitar H_0 , embora os dados não sejam aleatórios.

- Nem sempre é fácil decidir com base apenas na observação;
- Pequenas diferenças podem gerar dúvida;
- Alguns padrões não são detectados por frequência;

Motivação: precisamos de um critério objetivo para tomar decisões.

Teste do qui-quadrado

Na atividade realizada, foram obtidas tabelas de frequências para cada conjunto de dados.

- f_i : frequência observada em cada categoria;
- E_i : frequência esperada segundo o modelo teórico;
- k : número de categorias.

Se os dados forem compatíveis com o modelo, espera-se que:

$$f_i \approx E_i$$

Teste do qui-quadrado

Considere n observações classificadas em k classes.

Sejam:

- f_i : frequências observadas;
- $E_i = n \cdot p_i$: frequências esperadas, segundo o modelo.

A estatística do teste é dada por:

$$\chi^2 = \sum_{i=1}^k \frac{(f_i - E_i)^2}{E_i}$$

Se os dados seguem a distribuição proposta, então χ^2 tende a assumir valores pequenos.

Teste do qui-quadrado

Para tomar uma decisão, compara-se o valor de χ^2 com um valor crítico da distribuição qui-quadrado.

- valores pequenos de χ^2 indicam boa concordância;
- valores grandes indicam discrepâncias significativas.

Dado um nível de significância α :

rejeita-se H_0 se χ^2 exceder o valor crítico.

Observação: recomenda-se que $E_i > 5$ em todas as classes.

Teste do qui-quadrado

Exemplo: considere dados com valores entre 0 e 9.

Para este exemplo, os valores serão agrupados em 5 classes:

$$\{0, 1\}, \{2, 3\}, \{4, 5\}, \{6, 7\}, \{8, 9\}$$

Assim:

- o número de categorias é $k = 5$;
- cada classe reúne dois valores;
- essa escolha facilita a comparação das frequências.

Teste do qui-quadrado

Considere o seguinte conjunto de dados:

0, 3, 7, 1, 9, 5, 1, 8, 4, 6, 2, 7, 0, 5, 9, 3, 6, 1, 8, 4

Total de observações:

$$n = 20$$

Teste do qui-quadrado

Contando os valores em cada classe, obtêm-se:

$$f = (5, 3, 4, 4, 4)$$

Como $k = 5$, a frequência esperada é:

$$E = \frac{n}{k} = 4$$

Observação: *neste exemplo, o valor esperado é pequeno, sendo utilizado apenas para fins ilustrativos.*

Teste do qui-quadrado

Substituindo na fórmula:

$$\chi^2 = \frac{(5 - 4)^2}{4} + \frac{(3 - 4)^2}{4} + \frac{(4 - 4)^2}{4} + \frac{(4 - 4)^2}{4} + \frac{(4 - 4)^2}{4}$$

$$\chi^2 = \frac{1}{4} + \frac{1}{4} + 0 + 0 + 0 = 0,5$$

Interpretação: pequenas diferenças entre frequências observadas e esperadas resultam em um valor pequeno de χ^2 .

Distribuição qui-quadrado

Ao calcular χ^2 , obtém-se um número que mede a diferença entre frequências observadas e esperadas.

Mas como saber se o valor obtido, $\chi^2 = 0,5$, é grande ou pequeno?

Para isso, utiliza-se a **distribuição qui-quadrado**, que descreve o comportamento esperado de χ^2 quando H_0 é verdadeira.

Distribuição qui-quadrado

A distribuição qui-quadrado depende do número de **graus de liberdade**:

$$gl = k - 1$$

Para um nível de significância de 5%, define-se um valor limite (valor crítico), que depende de gl .

- valores pequenos de χ^2 são esperados quando H_0 é verdadeira;
- valores muito grandes são improváveis.

Se χ^2 exceder esse valor, rejeita-se H_0 .

Distribuição qui-quadrado

Geração de tabela de valores críticos em Python:

```
from scipy.stats import chi2

alfas = [0.10, 0.05, 0.01]
gls = [1, 2, 3, 4, 5]

print(" gl |  alpha=0.10 |  alpha=0.05 |  alpha=0.01")
print("-" * 46)

for gl in gls:
    valores = [chi2.ppf(1 - a, gl) for a in alfas]
    print(f"{gl:>3} | {valores[0]:>11.3f} | "
          f"{valores[1]:>11.3f} | {valores[2]:>11.3f}")
```

Distribuição qui-quadrado

Tabela de valores críticos:

gl	alpha=0.10	alpha=0.05	alpha=0.01
1	2.706	3.841	6.635
2	4.605	5.991	9.210
3	6.251	7.815	11.345
4	7.779	9.488	13.277
5	9.236	11.070	15.086

Para o exemplo: **gl = 4** e $\alpha = 0,05$, obtém-se:

$$\chi^2_{0,05;4} \approx 9,488$$

Distribuição qui-quadrado

Exercício:

Utilizando a tabela gerada:

- Determine o valor crítico para:

- ▶ $gl = 3, \alpha = 0,05;$
- ▶ $gl = 5, \alpha = 0,10;$
- ▶ $gl = 4, \alpha = 0,01.$

Pergunta: como o valor crítico varia com gl e α ?

Distribuição qui-quadrado

Como o valor crítico varia?

Em relação aos graus de liberdade (g):

- quanto maior g , maior o valor crítico;
- mais categorias $\Rightarrow$ maior variação possível nos dados.

Em relação ao nível de significância (α):

- quanto menor α , maior o valor crítico;
- menor $\alpha \Rightarrow$ teste mais rigoroso para rejeitar H_0 .

Ideia central: quanto mais rigoroso o teste, maior deve ser o valor de χ^2 para rejeitar H_0 .

Teste do qui-quadrado

Como $k = 5$, o número de graus de liberdade é:

$$k - 1 = 4$$

Para um nível de significância de 5%, o valor crítico é:

$$\chi^2_{0,05;4} \approx 9,488$$

Como:

$$0,5 < 9,488$$

não se rejeita H_0 .

Teste do qui-quadrado

Neste exemplo, o valor de χ^2 foi pequeno.

Isso indica que as diferenças entre as frequências observadas e esperadas são compatíveis com variações aleatórias.

Portanto, **não há evidências para rejeitar H_0** , e os dados são compatíveis com uma distribuição uniforme nas classes consideradas.

Teste do qui-quadrado

No exemplo anterior, o teste foi aplicado a um conjunto pequeno de dados.

Agora, será analisado um arquivo com 1000 observações.

- os dados serão lidos de um arquivo texto;
- as frequências serão calculadas automaticamente;
- o teste do qui-quadrado será aplicado por meio de um programa em Python.

Teste do qui-quadrado

```
from scipy.stats import chi2

# Leitura dos dados do arquivo
dados = []
with open("dados2.txt", "r") as arq:
    for linha in arq:
        linha = linha.strip()
        if linha:
            dados.append(int(linha))

# Parametros do teste
n = len(dados)
k = 5
E = n / k          # Distribuicao uniforme
alpha = 0.05

# Classes: {0,1}, {2,3}, {4,5}, {6,7}, {8,9}
frequencias = [0] * k
...
```

Teste do qui-quadrado

```
...
for valor in dados:
    indice = valor // 2
    frequencias[indice] += 1

# Calculo do qui-quadrado
chi2_calculado = sum((f - E) ** 2 / E for f in frequencias)

# Graus de liberdade e valor critico
graus_de_liberdade = k - 1
chi2_critico = chi2.ppf(1 - alpha, graus_de_liberdade)
...
```

Teste do qui-quadrado

```
...  
# Exibicao dos resultados  
print(f"Quantidade de dados lidos: {n}")  
print(f"Frequencias observadas: {frequencias}")  
print(f"Frequencia esperada em cada classe: {E:.1f}")  
print(f"Estatistica qui-quadrado calculada: {chi2_calculado  
    :.4f}")  
print(f"Valor critico (alpha={alpha}): {chi2_critico:.4f}")  
  
if chi2_calculado <= chi2_critico:  
    print("\nResultado: Nao se rejeita H0")  
else:  
    print("\nResultado: Rejeita-se H0")
```

Teste do qui-quadrado

Saída do Programa:

```
Quantidade de dados lidos: 1000
Frequencias observadas: [361, 270, 185, 122, 62]
Frequencia esperada em cada classe: 200.0
Estatistica qui-quadrado calculada: 280.8700
Valor critico (alpha=0.05): 9.4877

Resultado: Rejeita-se H0
```

Interpretação: as frequências observadas diferem significativamente das esperadas.

Atividade para entrega no SIGAA

Com base no programa apresentado em aula, desenvolva uma versão modificada que aplique o teste do qui-quadrado aos arquivos:

`dados2.txt` e `dados3.txt`.

O programa deve:

- ler os dados de cada arquivo;
- calcular as frequências observadas nas classes:

$\{0, 1\}$, $\{2, 3\}$, $\{4, 5\}$, $\{6, 7\}$, $\{8, 9\}$;

- calcular a estatística χ^2 ;
- determinar a decisão do teste para:

$\alpha = 0,10, 0,05, 0,01$.

Atividade para entrega no SIGAA

Para cada arquivo, o programa deve apresentar:

- o número total de dados lidos;
- a tabela de frequências observadas e esperadas;
- o valor calculado de χ^2 ;
- o valor crítico e a decisão do teste para cada α .

Atividade para entrega no SIGAA

Além do programa, deve-se apresentar uma análise comparativa contendo:

- em qual conjunto H_0 é rejeitada e em qual não;
- qual conjunto apresenta maior valor de χ^2 ;
- o que isso indica sobre a distribuição dos dados;
- uma justificativa com base na comparação entre χ^2 e os valores críticos.

A análise deve ser objetiva e baseada nos resultados obtidos. A resposta desta análise deve ser acrescentada no código Python como comentário ao final.

Validação do Conjunto de Dados

ECOS04 - Simulação e Avaliação de Desempenho

Edmilson Marmo Moreira
edmarmo@unifei.edu.br

Universidade Federal de Itajubá - UNIFEI
Instituto de Engenharia de Sistemas e Tecnologias da Informação - IESTI