

Conceitos Básicos de Probabilidade

ECOS04 - Simulação e Avaliação de Desempenho

Edmilson Marmo Moreira
edmarmo@unifei.edu.br

Universidade Federal de Itajubá - UNIFEI
Instituto de Engenharia de Sistemas e Tecnologias da Informação - IESTI

Laboratório 1: Introdução à Simulação e Análise de Dados

Objetivos:

- Ler dados a partir de um arquivo texto;
- Calcular medidas de tendência central;
- Calcular medidas de dispersão;
- Introduzir a média aparada;
- Trabalhar conceitos iniciais de probabilidade;
- Aplicar probabilidade condicional e Teorema de Bayes.

Preparação dos dados

Experimento 1: gerando o arquivo de dados

```
import random

dados = []
for _ in range(90):
    dados.append(random.randint(40, 80))
for _ in range(5):
    dados.append(random.randint(0, 10))
for _ in range(5):
    dados.append(random.randint(90, 120))

random.shuffle(dados)
with open("dados.txt", "w") as arq:
    for valor in dados:
        arq.write(f"{valor}\n")

print("Arquivo gerado com", len(dados), "valores.")
```

Média Aparada

A **média aparada** é uma medida de tendência central obtida a partir da exclusão de um número fixo de valores nas extremidades do conjunto de dados ordenado.

Sejam os dados ordenados

$$x_{(1)} \leq x_{(2)} \leq \cdots \leq x_{(n)}$$

e seja k o número de elementos removidos em cada extremidade.

Média Aparada

A **média aparada** é uma medida de tendência central obtida a partir da exclusão de um número fixo de valores nas extremidades do conjunto de dados ordenado.

Sejam os dados ordenados

$$x_{(1)} \leq x_{(2)} \leq \cdots \leq x_{(n)}$$

e seja k o número de elementos removidos em cada extremidade.

A média aparada é definida por:

$$\bar{x}_{ap} = \frac{1}{n - 2k} \sum_{i=k+1}^{n-k} x_{(i)}$$

Média Aparada

A **média aparada** é uma medida de tendência central obtida a partir da exclusão de um número fixo de valores nas extremidades do conjunto de dados ordenado.

Sejam os dados ordenados

$$x_{(1)} \leq x_{(2)} \leq \cdots \leq x_{(n)}$$

e seja k o número de elementos removidos em cada extremidade.

A média aparada é definida por:

$$\bar{x}_{ap} = \frac{1}{n - 2k} \sum_{i=k+1}^{n-k} x_{(i)}$$

Interpretação:

remove-se os k menores e os k maiores valores, calculando-se a média dos elementos restantes.

Experimento: Média Simples e Média Aparada

Com base no arquivo `dados.txt`, desenvolva um programa em Python que:

- 1 leia os 100 valores do arquivo;
- 2 calcule a **média aritmética simples**;
- 3 calcule a **média aparada**;
- 4 considere

$$k = 2, 4, 6, 8, 10$$

- 5 imprima uma **tabela comparativa**.

A saída deve ter o seguinte formato:

Média	$k = 2$	$k = 4$	$k = 6$	$k = 8$	$k = 10$
-------	---------	---------	---------	---------	----------

Média aparada

Experimento 2: calculando a média aparada

```
with open("dados.txt", "r") as arq:
    dados = [int(linha.strip()) for linha in arq if linha.
              strip()]

dados_ordenados = sorted(dados)
media_simples = sum(dados) / len(dados)

valores_k = [2, 4, 6, 8, 10]

medias_aparadas = []
for k in valores_k:
    dados_aparados = dados_ordenados[k:-k]
    media_aparada = sum(dados_aparados) / len(dados_aparados)
    medias_aparadas.append(media_aparada)

#continua...
```

Média aparada

```
#continuacao...

print(f"{'Media':>10}", end=" ")
for k in valores_k:
    print(f"{'k={k}':>10}", end=" ")
print()

print(f"{media_simples:10.2f}", end=" ")
for media in medias_aparadas:
    print(f"{media:10.2f}", end=" ")
print()
```

Experimento 2: calculando a média aparada - versão numpy

```
import numpy as np
from scipy.stats import trim_mean

with open("dados.txt", "r") as arq:
    dados = np.array([int(linha.strip()) for linha in arq])

media = np.mean(dados)
valores_k = [2, 4, 6, 8, 10]

#continua...
```

Média aparada

```
#continuacao...

print(f"{'Media':>10}", end=" ")
for k in valores_k:
    print(f"{'k={k}':>10}", end=" ")
print()

print(f"{media:10.2f}", end=" ")
for k in valores_k:
    media_aparada = trim_mean(dados, proportiontocut=k/100)
    print(f"{media_aparada:10.2f}", end=" ")

print()
```

Exercício para Entrega

Com base no código apresentado na nota de aula para o cálculo de:

- média aritmética;
- variância;
- desvio padrão;
- coeficiente de variação;
- amplitude;

modifique o programa para considerar também a **média aparada**.

Utilize o valor:

$$k = 4$$

isto é, remova os 4 menores e os 4 maiores valores do conjunto.

Após a aparagem, recalcule as medidas de dispersão a partir da média aparada.

Parte 2: Probabilidade

Nesta etapa do laboratório, serão desenvolvidos experimentos envolvendo:

- probabilidade simples;
- probabilidade condicional;
- aplicação do Teorema de Bayes.

O objetivo é utilizar Python para modelar e analisar um problema probabilístico.

Exemplo Motivador

Considere um sistema de filtragem de e-mails.

Sabemos que:

- 20% dos e-mails são spam;
- o filtro detecta spam corretamente em 90% dos casos;
- 10% dos e-mails legítimos são classificados como spam.

Exemplo Motivador

Considere um sistema de filtragem de e-mails.

Sabemos que:

- 20% dos e-mails são spam;
- o filtro detecta spam corretamente em 90% dos casos;
- 10% dos e-mails legítimos são classificados como spam.

Pergunta:

Se um e-mail foi marcado como spam, qual a probabilidade de ele realmente ser spam?

Relembrando: Probabilidade Condicional e Bayes

Probabilidade condicional:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Relembrando: Probabilidade Condicional e Bayes

Probabilidade condicional:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Teorema de Bayes: Quando conhecemos a condicional inversa $P(A|B)$ e desejamos calcular $P(B|A)$:

$$P(B|A) = \frac{P(A|B) P(B)}{P(A)}$$

Relembrando: Probabilidade Condicional e Bayes

Probabilidade condicional:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Teorema de Bayes: Quando conhecemos a condicional inversa $P(A|B)$ e desejamos calcular $P(B|A)$:

$$P(B|A) = \frac{P(A|B) P(B)}{P(A)}$$

Forma expandida:

$$P(B|A) = \frac{P(A|B)P(B)}{P(A|B)P(B) + P(A|B^c)P(B^c)}$$

Experimento: Implementação em Python

Desenvolva um programa em Python para calcular:

$$P(\text{Spam}|\text{Marcado como Spam})$$

utilizando o Teorema de Bayes.

Considere:

$$P(S) = 0.20$$

$$P(M|S) = 0.90$$

$$P(M|S^c) = 0.10$$

Exiba o resultado em porcentagem.

Solução em Python

```
P_S = 0.20
P_M_dado_S = 0.90
P_M_dado_nao_S = 0.10

P_nao_S = 1 - P_S

P_S_dado_M = (
    P_M_dado_S * P_S
) / (
    P_M_dado_S * P_S +
    P_M_dado_nao_S * P_nao_S
)

print(f"{P_S_dado_M*100:.2f}%")
```

Exercício para Entrega

Considere o arquivo `emails.txt` com a seguinte estrutura:

ID	Spam Real	Classificado
1	1	1
2	0	1
3	1	1
4	0	0

Significado das colunas:

- **ID:** identificador do e-mail;
- **Spam Real:** 1 se o e-mail é realmente spam;
- **Classificado:** 1 se o filtro marcou como spam.

Exercício para Entrega

Desenvolva um programa em Python que leia o arquivo `emails.txt` e determine:

$$P(M|S) \quad \text{e} \quad P(S|M)$$

onde:

- S : o e-mail é realmente spam;
- M : o e-mail foi marcado como spam.

O programa deve calcular $P(S|M)$ de duas formas:

- 1 usando o Teorema de Bayes;
- 2 usando a contagem direta no arquivo.

Exercício para Entrega

Para o cálculo analítico, utilize:

$$P(S|M) = \frac{P(M|S)P(S)}{P(M|S)P(S) + P(M|S^c)P(S^c)}$$

Para a verificação por contagem direta, utilize:

$$P(S|M) = \frac{\#(S \cap M)}{\#(M)}$$

Entrega:

código-fonte e arquivo contendo a saída produzida pelo programa.

Conceitos Básicos de Probabilidade

ECOS04 - Simulação e Avaliação de Desempenho

Edmilson Marmo Moreira
edmarmo@unifei.edu.br

Universidade Federal de Itajubá - UNIFEI
Instituto de Engenharia de Sistemas e Tecnologias da Informação - IESTI