

Capítulo 2

Variáveis Aleatórias e Distribuições de Probabilidade

Edmilson Marmo Moreira

Universidade Federal de Itajubá - UNIFEI

Instituto de Engenharia de Sistemas e Tecnologias da Informação - IESTI

“Não é o desafio que define quem somos nem o que somos capazes de ser, mas como enfrentamos esse desafio: podemos incendiar as ruínas ou construir, através delas e passo a passo, um caminho que nos leve à liberdade”.

Richard Bach

1 Considerações Iniciais

A ideia de variável aleatória tem o objetivo de associar eventos do espaço amostral a valores numéricos no conjunto dos números reais. Entretanto, o termo “**variável aleatória**” pode ser enganoso, pois, no sentido estrito da palavra, trata-se de uma função matemática que mapeia os resultados de um experimento aleatório para números reais.

Em essência, uma variável aleatória pode ser vista como uma variável dependente, cujo valor resulta de um experimento probabilístico. Embora o termo “**aleatória**” sugira incerteza, a função que define a variável é bem estabelecida e determinística em seu domínio.

Formalmente, define-se:

Definição 1.1 *Uma **variável aleatória** é uma função*

$$X : \Omega \rightarrow \mathbb{R}$$

que associa a cada resultado do espaço amostral Ω um número real.

Diferentes resultados do espaço amostral podem ser associados ao mesmo valor real, de modo que os conjuntos

$$\{\omega \in \Omega : X(\omega) = x\}$$

formam uma partição do espaço amostral correspondente aos possíveis valores assumidos por X .

As variáveis aleatórias desempenham um papel fundamental na modelagem de incertezas em áreas como estatística, simulação e análise de desempenho. Elas permitem

descrever resultados incertos por meio de valores numéricos associados a eventos em um espaço amostral.

A notação convencional utiliza letras maiúsculas, como X , Y , etc., para representar uma variável aleatória. Um valor específico que a variável pode assumir é denotado pela letra minúscula correspondente: x , y , etc.

2 Classificação das variáveis aleatórias

As variáveis aleatórias podem ser classificadas de acordo com a natureza de seus valores:

- **Variável Aleatória Discreta:** Assume um número finito ou infinitamente contável de valores. São exemplos desta classe:
 - O número de chamadas recebidas em um *call center* durante uma hora.
 - O número de peças defeituosas em um lote de produção.
- **Variável Aleatória Contínua:** Pode assumir qualquer valor dentro de um intervalo da reta real. Os exemplos a seguir ilustram esta classe:
 - O tempo necessário para atender um cliente em um caixa de supermercado.
 - A altura de estudantes em uma escola.

As variáveis aleatórias também podem ser classificadas de acordo com a quantidade de dimensões:

- **Variável Aleatória Unidimensional:** Quando representa uma única característica de um experimento aleatório. Um exemplo para este tipo seria o registro da temperatura em uma cidade ao meio-dia.
- **Variável Aleatória Multidimensional:** Quando representa múltiplas características simultaneamente. Como exemplo poderia ser citado o registro da pressão arterial e o nível de glicose de um paciente em um exame médico.

3 Variáveis Aleatórias Discretas

Para descrever completamente uma variável aleatória discreta, é necessário conhecer tanto os valores que ela pode assumir quanto as probabilidades associadas a esses valores.

Para facilitar o entendimento deste conceito, considere o lançamento de dois dados justos. O espaço amostral é composto pelos pares ordenados (i, j) , onde $i, j \in \{1, 2, 3, 4, 5, 6\}$. Suponha que a variável aleatória X represente o *valor máximo das faces obtidas*. Os possíveis valores de X são 1, 2, 3, 4, 5, 6, com os eventos correspondentes:

- $X = 1 : \{(1, 1)\}$
- $X = 2 : \{(1, 2), (2, 1), (2, 2)\}$
- $X = 3 : \{(1, 3), (2, 3), (3, 1), (3, 2), (3, 3)\}$
- $X = 4 : \{(1, 4), (2, 4), (3, 4), (4, 1), (4, 2), (4, 3), (4, 4)\}$
- $X = 5 : \{(1, 5), (2, 5), (3, 5), (4, 5), (5, 1), (5, 2), (5, 3), (5, 4), (5, 5)\}$
- $X = 6 : \{(1, 6), (2, 6), (3, 6), (4, 6), (5, 6), (6, 1), (6, 2), (6, 3), (6, 4), (6, 5), (6, 6)\}$

A probabilidade de cada valor é calculada dividindo o número de elementos do evento correspondente pelo total de possíveis resultados, 36. Por exemplo:

$$P(X = 2) = \frac{3}{36}$$

As demais probabilidades são:

- $P(X = 1) = \frac{1}{36}$
- $P(X = 3) = \frac{5}{36}$
- $P(X = 4) = \frac{7}{36}$
- $P(X = 5) = \frac{9}{36}$
- $P(X = 6) = \frac{11}{36}$

Esse exemplo ilustra o conceito de **função massa de probabilidade (FMP)** de uma variável aleatória discreta, que descreve a distribuição de probabilidades dos valores assumidos por X .

Definição 3.1 *Seja X uma variável aleatória discreta. A **função massa de probabilidade** de X é a função $f_X(x)$ que associa, a cada valor possível x de X , sua respectiva probabilidade, calculada como:*

$$f_X(x) = P(\{X = x\}) = \sum_{\omega \in \Omega: X(\omega)=x} P(\omega).$$

Para simplificar a notação, costuma-se escrever $P(X = x)$ em vez de $P(\{X = x\})$. A função $f_X(x)$ deve satisfazer as seguintes propriedades:

1. $0 \leq f_X(x) \leq 1$, para todo $x \in \mathbb{R}_X$.

2. A soma das probabilidades para todos os valores possíveis de X é igual a 1:

$$\sum_x f_X(x) = 1$$

Essa segunda propriedade decorre do axioma $P(\Omega) = 1$, pois, para valores distintos de x , os eventos $\{X = x\}$ são mutuamente exclusivos e, em conjunto, formam uma partição do espaço amostral.

É possível resumir o cálculo da função massa de probabilidade de uma variável aleatória X em três etapas:

1. Identificar todos os possíveis valores x da variável aleatória X .
2. Identificar os resultados que originam cada valor x e suas respectivas probabilidades.
3. Somar todas as probabilidades para obter $f_X(x)$.

Considerando novamente a variável aleatória do exemplo inicial, pode-se resumir a FMP da variável em questão na seguinte tabela:

x	1	2	3	4	5	6
$f_X(x)$	$\frac{1}{36}$	$\frac{3}{36}$	$\frac{5}{36}$	$\frac{7}{36}$	$\frac{9}{36}$	$\frac{11}{36}$

A Figura 1 ilustra essa distribuição de probabilidade:




Figura 1: Função Massa de Probabilidade do exemplo $X = \text{valor máximo das faces}$

O diagrama da Figura 1 foi gerado pela execução do código Python a seguir.

```

import matplotlib.pyplot as plt

# Valores possíveis da variável aleatória X
x_values = [1, 2, 3, 4, 5, 6]

# Probabilidades correspondentes
probabilities = [1/36, 3/36, 5/36, 7/36, 9/36, 11/36]

# Criar o gráfico
plt.stem(x_values, probabilities, basefmt=" ", linefmt="b-", markerfmt="bo")

# Adicionar rótulos
plt.title("Função Massa de Probabilidade")
plt.xlabel("Valor de X")
plt.ylabel("Probabilidade P(X=x)")

# Exibir o gráfico
plt.grid(True)
plt.show()

```

Neste programa, o comando `plt.stem` da biblioteca **Matplotlib** gera um gráfico de haste para representar distribuições discretas, onde cada valor em `x_values` (eixo x) é associado a uma probabilidade em `probabilities` (eixo y), exibindo linhas verticais (`linefmt="b-"`) com marcadores circulares (`markerfmt="bo"`) no topo para destacar os pontos, enquanto `basefmt=" "` remove a linha de base, resultando em uma visualização clara da função massa de probabilidade $P(X = x)$.

3.1 Função de Distribuição Acumulada

A função massa de probabilidade (FMP) de uma variável aleatória discreta X descreve completamente sua distribuição. Considerando novamente a variável aleatória $X = \text{“valor máximo das faces de 2 dados”}$, a partir da FMP de X , é possível calcular probabilidades como:

$$P(X \geq 5) = P(X = 5) + P(X = 6) = \frac{9}{36} + \frac{11}{36} = \frac{20}{36}$$

Embora a função de massa de probabilidade contenha todas as informações sobre X , a **função de distribuição acumulada (FDA)**, denotada por $F_X(x)$, também é fundamental e complementa a FMP ao fornecer probabilidades acumuladas.

Definição 3.2 Dada uma variável aleatória (discreta) X , a **função de distribuição acumulada** de X é definida por:

$$F_X(x) = P(X \leq x), \quad \forall x \in \mathbb{R}$$

A função F_X está definida para todo número real x . Por exemplo, no “valor máximo das faces de 2 dados”, para $x = 1$, tem-se:

$$F_X(1) = P(X \leq 1) = P(X < 1) + P(X = 1) = \frac{1}{36}$$

Nesta expressão, é importante destacar que $P(X < 1) = 0$, pois nenhum valor menor que 1 é possível. De forma análoga, pode-se calcular $F_X(x)$ para outros valores de x :

$$F_X(2) = P(X \leq 2) = P(X \leq 1) + P(1 < X \leq 2) + P(X = 2) = \frac{4}{36}$$

e seguindo o mesmo raciocínio:

- $F_X(3) = \frac{9}{36}$
- $F_X(4) = \frac{16}{36}$
- $F_X(5) = \frac{25}{36}$

Para $x \geq 6$, o evento $\{X \leq x\}$ corresponde ao espaço amostral completo. Portanto:

$$F_X(x) = 1 \quad \forall x \geq 6$$

Desta forma, a função de distribuição acumulada deste exemplo é dada por:

$$F_X(x) = \begin{cases} 0 & \text{se } x < 1 \\ \frac{1}{36} & \text{se } 1 \leq x < 2 \\ \frac{4}{36} & \text{se } 2 \leq x < 3 \\ \frac{9}{36} & \text{se } 3 \leq x < 4 \\ \frac{16}{36} & \text{se } 4 \leq x < 5 \\ \frac{25}{36} & \text{se } 5 \leq x < 6 \\ 1 & \text{se } x \geq 6 \end{cases}$$

A Figura 2 apresenta o gráfico da função de distribuição acumulada da variável aleatória estudada. Neste gráfico, a escala vertical está em múltiplos de 36 e a função assume a forma de uma “escada”, com saltos de descontinuidade nos valores da variável aleatória X .




Figura 2: Função de distribuição acumulada de $X = \text{valor máximo das faces}$

O código Python apresentado a seguir gera o gráfico da Função de Distribuição Acumulada (FDA) para a variável aleatória discreta X (*máximo entre dois dados*), que resultou no gráfico da Figura 2.

```
import numpy as np
import matplotlib.pyplot as plt

# Valores de X e as probabilidades acumuladas
x = [1, 2, 3, 4, 5, 6]
F_X = [1/36, 4/36, 9/36, 16/36, 25/36, 1]

# Adiciona um ponto extra para representar o comportamento constante
# após x=6
x = [0] + x + [7]
F_X = [0] + F_X + [1]

# Plota os pontos
plt.plot(x, F_X, 'bo', markersize=5) # pontos azuis

# Plota as linhas horizontais entre os pontos
for i in range(1, len(x)):
    plt.hlines(F_X[i-1], x[i-1], x[i], colors='b', linestyle='solid')

# Adiciona as linhas verticais para indicar os saltos (mas não conecta
# os pontos)
```

```

for i in range(1, len(x) - 1):
    plt.vlines(x[i], F_X[i-1], F_X[i], colors='b', linestyle='dotted')

# Configurações do gráfico
plt.title("Função de Distribuição Acumulada de X")
plt.xlabel("x")
plt.ylabel(r"$F_X(x)$")
plt.grid(True)
plt.show()

```

Este código destaca-se em relação ao programa que gerou a função massa de probabilidade (FMP) em vários aspectos: enquanto o código da FMP usava `plt.stem` para criar hastes verticais que representavam probabilidades pontuais (como $P(X=2) = 3/36$), este código da FDA utiliza `plt.plot`, `plt.hlines` e `plt.vlines` para construir uma escada acumulativa, onde:

- Os pontos azuis ('bo') marcam os valores acumulados em cada x , e as linhas horizontais (`plt.hlines`) conectam esses pontos, mostrando que $F_X(x)$ permanece constante entre os valores discretos.
- As linhas verticais (`plt.vlines`) com estilo 'dotted' indicam os saltos da FDA nos valores específicos de X , diferindo da FMP, que não mostra acumulação.
- O código também adiciona pontos extras em $x = 0$ e $x = 7$ (com $F_X(0) = 0$ e $F_X(7) = 1$) para garantir que o gráfico reflita corretamente o comportamento da FDA fora do intervalo discreto, algo desnecessário na FMP, que só existe nos pontos discretos.

Essas diferenças visuais e estruturais refletem a natureza distinta das duas funções: a FMP descreve probabilidades individuais, enquanto a FDA mostra como essas probabilidades se acumulam até um limite x .

3.2 Esperança e variância de variáveis aleatórias discretas

O **valor esperado** (ou **esperança matemática**) de uma variável aleatória representa a média teórica de uma variável aleatória em um grande número de repetições do experimento.

Definição 3.3 *Seja X uma variável aleatória discreta que assume os valores $x_1, x_2, \dots$ com probabilidades $p_1, p_2, \dots$, respectivamente. A **esperança** (ou **média**) de X é definida como:*

$$E(X) = \sum_i x_i \cdot P(X = x_i)$$

onde o somatório se estende por todos os valores possíveis de X .

A esperança é uma média ponderada dos valores possíveis de X , onde os pesos são as probabilidades associadas a cada valor.

As principais propriedades da Esperança Matemática são:

1. **Linearidade:** Para quaisquer variáveis aleatórias X e Y , e constantes a e b :

$$E(aX + bY) = aE(X) + bE(Y)$$

2. **Constante:** Se c é uma constante, então:

$$E(c) = c$$

3. **Independência:** Se X e Y são independentes, então:

$$E(XY) = E(X) \cdot E(Y)$$

Como exemplo, considere o lançamento de um dado justo. A variável aleatória X representa o resultado do lançamento, com valores possíveis 1, 2, 3, 4, 5, 6, cada um com probabilidade $\frac{1}{6}$. A esperança de X é:

$$E(X) = \sum_{x_i=1}^6 x_i \cdot \frac{1}{6} = \frac{21}{6} = 3,5.$$

Assim, o valor esperado do resultado de um dado justo é 3,5. Observe que o valor esperado para um dado justo pode parecer contra-intuitivo à primeira vista, já que não existe uma face do dado com esse valor. No entanto, a ideia do valor esperado não está relacionada a um resultado possível em um único lançamento, mas sim à média dos resultados ao longo de muitas repetições do experimento.

O valor esperado ($E(X)$) é uma medida teórica que representa o valor médio que se esperaria obter se repetisse o experimento um número muito grande de vezes. Por exemplo, se um dado for lançado 1.000 vezes, a média dos resultados será aproximadamente 3,5.

Para quantificar a variabilidade dos valores em torno da média, utiliza-se a **variância** e o **desvio padrão**.

Definição 3.4 A **variância** de uma variável aleatória X é definida como:

$$Var(X) = E[(X - E(X))^2].$$

ou alternativamente:

$$Var(X) = E(X^2) - [E(X)]^2,$$

onde $E(X^2)$ é a esperança do quadrado de X .

A variância mede a dispersão dos valores de X em torno da média. No entanto, como sua unidade é o quadrado da unidade de X , é comum utilizar o **desvio padrão**, que é a raiz quadrada da variância e possui a mesma unidade de X .

Definição 3.5 O *desvio padrão* de uma variável aleatória X é definido como:

$$DP(X) = \sqrt{Var(X)}$$

Considere novamente o lançamento de um dado justo, com $E(X) = 3,5$. Para calcular a variância, primeiro deve-se encontrar $E(X^2)$:

$$E(X^2) = \sum_{x=1}^6 x^2 \cdot \frac{1}{6} = 1^2 \cdot \frac{1}{6} + 2^2 \cdot \frac{1}{6} + \dots + 6^2 \cdot \frac{1}{6} = \frac{91}{6} \approx 15,1667$$

Em seguida, calcula-se a variância:

$$Var(X) = E(X^2) - [E(X)]^2 = \frac{91}{6} - \left(\frac{21}{6}\right)^2 = \frac{91}{6} - \frac{441}{36} = \frac{35}{12} \approx 2,9167.$$

O desvio padrão é:

$$DP(X) = \sqrt{\frac{35}{12}} \approx 1,7078.$$

Assim, a variância do resultado de um dado justo é aproximadamente 2,9167, e o desvio padrão é aproximadamente 1,7078.

O código Python a seguir realiza o cálculo apresentado.

```
# Definição dos possíveis valores da variável aleatória
valores = [1, 2, 3, 4, 5, 6]
probabilidade = 1/6 # Probabilidade uniforme para cada face do dado

# Cálculo da esperança matemática
esperanca = 0
for x in valores:
    esperanca += x * probabilidade

# Cálculo da esperança do quadrado da variável
esperanca_quadrado = 0
for x in valores:
    esperanca_quadrado += (x ** 2) * probabilidade

# Cálculo da variância
variancia = esperanca_quadrado - (esperanca ** 2)

# Exibição dos resultados
print(f"Esperanca matemática (E[X]): {esperanca:.2f}")
```

```
print(f"Esperanca do quadrado (E[X^2]): {esperanca_quadrado:.2f}")
print(f"Variancia (Var[X]): {variancia:.2f}")
```

O código define os valores possíveis do dado e calcula a esperança matemática iterando sobre a lista de valores e somando os produtos entre os valores e a probabilidade. Em seguida, repete o processo para calcular a esperança do quadrado dos valores. Por fim, a variância é obtida subtraindo o quadrado da esperança de $E(X^2)$ e os resultados são exibidos formatados com duas casas decimais.

O próximo código utiliza a biblioteca NumPy para simplificar os cálculos.

```
import numpy as np

# Definição dos possíveis valores da variável aleatória
valores = np.array([1, 2, 3, 4, 5, 6])
prob = 1/6 # Probabilidade uniforme para cada face do dado

# Cálculo da esperança matemática
esperanca = np.sum(valores * prob)

# Cálculo da esperança do quadrado da variável
esperanca_quadrado = np.sum((valores**2) * prob)

# Cálculo da variância
variancia = esperanca_quadrado - (esperanca ** 2)

# Exibição dos resultados
print(f"Esperanca matemática (E[X]): {esperanca:.2f}")
print(f"Esperanca do quadrado (E[X^2]): {esperanca_quadrado:.2f}")
print(f"Variancia (Var[X]): {variancia:.2f}")
```

4 Exemplos de distribuições discretas

Algumas distribuições discretas amplamente utilizadas são:

- Distribuição Uniforme Discreta;
- Distribuição de Bernoulli;
- Distribuição Binomial;
- Distribuição de Poisson.

4.1 Distribuição Uniforme Discreta

A **distribuição uniforme discreta** é uma distribuição de probabilidade em que todos os valores possíveis da variável aleatória têm a mesma probabilidade de ocorrer. É frequentemente usada para modelar situações em que não há preferência ou viés entre os resultados possíveis.

1. Parâmetros:

- n : Número de valores possíveis que a variável aleatória pode assumir.
- a : Valor mínimo (geralmente $a = 1$, mas pode ser qualquer inteiro).
- b : Valor máximo ($b = a + n - 1$).

2. Domínio:

- A variável aleatória X assume valores inteiros no intervalo $[a, b]$, ou seja:

$$X \in \{a, a + 1, a + 2, \dots, b\}$$

3. Função Massa de Probabilidade (FMP):

- A probabilidade de X assumir qualquer valor x no domínio é a mesma:

$$P(X = x) = \frac{1}{n}, \text{ para } x = a, a + 1, \dots, b.$$

Aqui, $n = b - a + 1$ é o número de valores possíveis.

4. Esperança (Valor Esperado):

- O valor esperado de X é a média dos valores possíveis:

$$E(X) = \frac{a + b}{2}.$$

5. Variância:

- A variância de X mede a dispersão dos valores em torno da média e é dada por:

$$Var(X) = \frac{(b - a + 1)^2 - 1}{12}.$$

6. Aplicações:

- Lançamento de dados, sorteios, escolhas aleatórias com probabilidades iguais.

7. A Figura 3 ilustra o formato da função massa de probabilidade de uma variável uniforme discreta.




Figura 3: Exemplo de distribuição Uniforme Discreta: $a = 1, b = 6$

4.2 Distribuição de Bernoulli

A **distribuição de Bernoulli** é uma distribuição de probabilidade que modela experimentos com apenas dois resultados possíveis: **sucesso** (1) e **fracasso** (0). Ela é amplamente utilizada para modelar situações em que há apenas dois resultados possíveis, como lançamento de moedas, resultados de testes binários (positivo/negativo) ou sucesso/fracasso em uma única tentativa.

1. Parâmetros:

- p : Probabilidade de sucesso ($0 \leq p \leq 1$).
- $1 - p$: Probabilidade de fracasso.

2. Domínio:

- A variável aleatória X assume apenas dois valores:

$$X \in \{0, 1\},$$

onde 0 representa fracasso e 1 representa sucesso.

3. Função Massa de Probabilidade (FMP):

- A probabilidade de X assumir cada valor é dada por:

$$P(X = x) = \begin{cases} 1 - p, & \text{se } x = 0, \\ p, & \text{se } x = 1. \end{cases}$$

4. Esperança (Valor Esperado):

- O valor esperado de X é a média ponderada dos valores possíveis:

$$E(X) = 0 \cdot (1 - p) + 1 \cdot p = p.$$

5. Variância:

- A variância de X mede a dispersão dos valores em torno da média e é dada por:

$$Var(X) = p \cdot (1 - p).$$

6. Aplicações:

- Lançamento de uma moeda (cara ou coroa).
- Resultado de um teste médico (positivo ou negativo).
- Sucesso ou fracasso em uma única tentativa.

7. A Figura 4 ilustra o formato da função massa de probabilidade da distribuição de Bernoulli.




Figura 4: Exemplo de distribuição de Bernoulli $p = 0,6$

4.3 Distribuição Binomial

A **distribuição binomial** é uma distribuição de probabilidade que modela o número de sucessos em n tentativas independentes de um experimento de Bernoulli, onde cada tentativa tem a mesma probabilidade de sucesso p . Ela é amplamente utilizada para modelar situações como o número de caras em n lançamentos de uma moeda ou o número de sucessos em n tentativas de um experimento.

1. Parâmetros:

- n : Número de tentativas independentes.
- p : Probabilidade de sucesso em cada tentativa ($0 \leq p \leq 1$).

2. Domínio:

- A variável aleatória X assume valores inteiros no intervalo:

$$X \in \{0, 1, 2, 3, \dots, n\},$$

onde X representa o número de sucessos em n tentativas.

3. Função Massa de Probabilidade (FMP):

- A probabilidade de X assumir um valor k (número de sucessos) é dada por:

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad \text{para } k = 0, 1, 2, \dots, n.$$

Aqui, $\binom{n}{k}$ é o coeficiente binomial, que representa o número de combinações de n tentativas tomadas k a k :

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}, \quad \text{onde } k \text{ é o número de sucessos.}$$

4. Esperança (Valor Esperado):

- O valor esperado de X é a média do número de sucessos em n tentativas:

$$E(X) = n \cdot p.$$

5. Variância:

- A variância de X mede a dispersão dos valores em torno da média e é dada por:

$$Var(X) = n \cdot p \cdot (1 - p).$$

6. Aplicações:

- Número de caras em n lançamentos de uma moeda.
- Número de peças defeituosas em um lote de n peças produzidas.
- Número de respostas corretas em um teste de múltipla escolha com n questões.

7. A Figura 5 ilustra o formato da função massa de probabilidade de uma variável aleatória binomial.




Figura 5: Exemplo de distribuição Binomial: $n = 10, p = 0,5$

4.4 Distribuição de Poisson

A **distribuição de Poisson** é uma distribuição de probabilidade que modela o número de eventos que ocorrem em um intervalo de tempo ou espaço fixo, quando esses eventos ocorrem com uma taxa média conhecida (λ) e de forma independente entre si. Ela é amplamente utilizada para modelar situações como o número de chamadas recebidas por uma central telefônica em uma hora ou o número de defeitos em um rolo de tecido.

1. Parâmetros:

- λ : Taxa média de ocorrência dos eventos no intervalo de tempo ou espaço.

2. Domínio:

- A variável aleatória X assume valores inteiros não negativos:

$$X \in \{0, 1, 2, 3, \dots\}.$$

3. Função Massa de Probabilidade (FMP):

- A probabilidade de X assumir um valor k (número de eventos) é dada por:

$$P(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}, \text{ para } k = 0, 1, 2, \dots.$$

Aqui, e é a constante de Euler ($e \approx 2,71828$) e $k!$ é o fatorial de k .

4. Esperança (Valor Esperado):

- O valor esperado de X é igual à taxa média de ocorrência:

$$E(X) = \lambda.$$

5. Variância:

- A variância de X mede a dispersão dos valores em torno da média e é dada por:

$$Var(X) = \lambda.$$

6. Aplicações:

- Número de chamadas recebidas por uma central telefônica em uma hora.
- Número de defeitos em um rolo de tecido.
- Número de acidentes em uma rodovia em um dia.

7. A Figura 6 ilustra o formato da função massa de probabilidade da distribuição de Poisson.




Figura 6: Exemplo de distribuição de Poisson: $\lambda = 3$

5 Variáveis Aleatórias Contínuas

Diferentemente das variáveis aleatórias discretas, que assumem valores isolados, uma variável aleatória contínua pode assumir infinitos valores dentro de um intervalo. Seu comportamento é descrito por uma **função densidade de probabilidade (FDP)**, que define a distribuição dos valores possíveis.

Uma consequência fundamental desse modelo é que a probabilidade da variável assumir um valor exato é sempre zero. Isso ocorre porque, em uma distribuição contínua, a probabilidade é medida pela área sob a curva da FDP em um intervalo. Como um único ponto não tem largura, sua área associada é nula. Assim, para qualquer valor específico x , tem-se:

$$P(X = x) = 0.$$

Por exemplo, considere o tempo necessário para concluir uma operação em um caixa eletrônico. Se esse tempo for modelado como uma variável aleatória contínua X , então a probabilidade de que exatamente 2 minutos sejam necessários é zero. Isso se deve ao fato de que o tempo pode assumir qualquer valor dentro de um intervalo contínuo, como 1,9999... ou 2,0001... minutos. No entanto, é possível calcular a probabilidade de que o tempo esteja dentro de um intervalo, como entre 1 e 3 minutos, utilizando a FDP correspondente.

Definição 5.1 *Seja X uma variável aleatória contínua. Sua **função densidade de pro-***

habilidade (FDP) é uma função $f_X(x)$ que satisfaz as seguintes propriedades:

1. $f_X(x) \geq 0$, para todo $x \in \mathbb{R}$.
2. A área total sob a curva da FDP é igual a 1:

$$\int_{-\infty}^{\infty} f_X(x)dx = 1.$$

3. A probabilidade de X estar em um intervalo $[a, b]$ é dada por:

$$P(a \leq X \leq b) = \int_a^b f_X(x)dx.$$

A função densidade de probabilidade fornece uma medida relativa da ocorrência de valores dentro de um intervalo. Por exemplo, dada uma função $f_X(x)$ satisfazendo as propriedades da definição acima, então, $f_X(x)$ representa alguma variável aleatória contínua X , de modo que $P(a \leq X \leq b)$ é a área sob a curva limitada pelos pontos a e b , conforme ilustra a Figura 7.




Figura 7: Probabilidade como área

5.1 Função de Distribuição Acumulada

Assim como a função massa de probabilidade no caso discreto, a função densidade de probabilidade contém todas as informações sobre a variável aleatória contínua X , ou seja, a partir da FDP, pode-se calcular qualquer probabilidade associada à variável X . Assim como no caso discreto, pode-se calcular probabilidades associadas a uma variável aleatória contínua X a partir da função de distribuição acumulada.

A **função de distribuição acumulada (FDA)** de uma variável aleatória contínua X é definida como a probabilidade de que X assumira um valor menor ou igual a x :

$$F_X(x) = P(X \leq x) = \int_{-\infty}^x f_X(t)dt.$$

A definição é a mesma vista para o caso discreto, a diferença é que para variáveis contínuas, a FDA é uma função contínua, sem saltos, como no exemplo da Figura 8.




Figura 8: Exemplo de FDA de uma variável aleatória contínua

Da interpretação de probabilidade como área, resulta que $F_X(x)$ é a área à esquerda de x sob a curva de densidade f_X , como ilustrado na Figura 9.




Figura 9: FDA - cálculo a partir da área sob a curva de densidade

A FDA tem as seguintes propriedades:

1. $F_X(x)$ é uma função não decrescente.
2. $\lim_{x \rightarrow -\infty} F_X(x) = 0$ e $\lim_{x \rightarrow \infty} F_X(x) = 1$.

3. $F_X(x)$ é contínua.

No exemplo do tempo de atendimento no caixa eletrônico, $F_X(3)$ representaria a probabilidade acumulada de que a operação tenha levado no máximo 3 minutos.

5.2 Esperança e Variância de Variáveis Aleatórias Contínuas

Para variáveis aleatórias contínuas, as definições de esperança e variância substituem somatórios por integrais, utilizando a função densidade de probabilidade (FDP) $f_X(x)$.

Definição 5.2 (Valor Esperado) A esperança de uma variável contínua X com densidade $f_X(x)$ é:

$$E(X) = \int_{-\infty}^{\infty} x \cdot f_X(x) dx.$$

desde que $\int_{-\infty}^{\infty} |x| f_X(x) dx < \infty$ (integral absolutamente convergente).

Definição 5.3 (Variância) A variância mede a dispersão quadrática em torno da média:

$$Var(X) = E[(X - E(X))^2] = \int_{-\infty}^{\infty} (x - E(X))^2 \cdot f_X(x) dx.$$

Definição 5.4 (Desvio Padrão) Escala a variância para a mesma unidade da variável:

$$DP(X) = \sqrt{Var(X)}.$$

5.3 Exemplo com Distribuição Uniforme Contínua

A distribuição uniforme contínua é um dos modelos mais simples para variáveis aleatórias contínuas. Ela é caracterizada por:

1. uma densidade de probabilidade constante dentro de um intervalo finito $[a, b]$;
2. probabilidade nula para valores fora desse intervalo.

Essa distribuição é frequentemente utilizada para modelar situações em que todos os valores dentro de um limite conhecido têm a mesma probabilidade de ocorrência.

Considere uma variável aleatória X representando o tempo de espera (em minutos) por um ônibus, assumindo que esse tempo seja uniformemente distribuído entre 0 e 10 minutos. A função densidade de probabilidade (FDP) é definida por:

$$f_X(x) = \begin{cases} \frac{1}{10}, & \text{se } 0 \leq x \leq 10 \\ 0, & \text{caso contrário} \end{cases}$$

A Figura 10 ilustra o gráfico da função de densidade de probabilidade para esse exemplo.




Figura 10: Gráfico da Função Densidade de Probabilidade (FDP)

A probabilidade de esperar entre 2 e 5 minutos pode ser determinada integrando a FDP no intervalo correspondente:

$$P(2 \leq X \leq 5) = \int_2^5 \frac{1}{10} dx = \frac{3}{10} = 0.3$$

Analogamente, a probabilidade de esperar menos de 4 minutos é:

$$P(X \leq 4) = \int_0^4 \frac{1}{10} dx = \frac{4}{10} = 0.4$$

A função de distribuição acumulada (FDA) corresponde à probabilidade de X assumir valores menores ou iguais a um determinado valor x :

$$F_X(x) = P(X \leq x) = \int_0^x \frac{1}{10} dt = \frac{x}{10}, \quad 0 \leq x \leq 10.$$

Para outros valores de x :

- $F_X(x) = 0$ se $x < 0$
- $F_X(x) = 1$ se $x > 10$

A Figura 11 apresenta o gráfico da FDA para este exemplo.

Os valores esperados para a média, variância e desvio padrão são obtidos pelas seguintes expressões:

$$E(X) = \int_0^{10} x \cdot \frac{1}{10} dx = 5 \text{ minutos}$$




Figura 11: Gráfico da Função de Distribuição Acumulada (FDA)

$$Var(X) = \int_0^{10} (x - 5)^2 \cdot \frac{1}{10} dx = \frac{25}{3} \text{ minutos}^2$$

$$DP(X) = \sqrt{Var(X)} = \frac{5}{\sqrt{3}} \approx 2.89 \text{ minutos}$$

Com base nos cálculos apresentados, conclui-se que:

- o tempo médio de espera pelo ônibus é de 5 minutos;
- a probabilidade de esperar entre 2 e 5 minutos é de 30%;
- a probabilidade de esperar menos de 4 minutos é de 40%;
- a variância e o desvio padrão indicam que os tempos de espera variam em torno da média, com um desvio padrão de aproximadamente 2,89 minutos.

6 Exemplos de Distribuições Contínuas

A seguir, são apresentadas, de forma sistematizada, algumas das principais distribuições contínuas utilizadas na modelagem de variáveis aleatórias.

Entre as distribuições contínuas mais utilizadas, destacam-se:

- Distribuição Uniforme Contínua;
- Distribuição Normal (Gaussiana);

- Distribuição Exponencial;
- Distribuição Gama;
- Distribuição Beta.

6.1 Distribuição Uniforme Contínua

A distribuição uniforme contínua já foi introduzida na Seção 5.3 por meio do exemplo do tempo de espera por um ônibus. De forma geral, essa distribuição é utilizada quando todos os valores de um intervalo possuem a mesma densidade de probabilidade.

Se $X \sim U(a, b)$, com $a < b$, então sua função densidade de probabilidade é dada por

$$f(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b \\ 0, & \text{caso contrário} \end{cases}$$

A esperança e a variância são dadas por

$$E(X) = \frac{a+b}{2}$$

$$Var(X) = \frac{(b-a)^2}{12}$$

Trata-se de uma distribuição amplamente utilizada na modelagem de tempos, intervalos e na geração de números aleatórios em simulação computacional.

6.2 Distribuição Normal (Gaussiana)

A **distribuição normal** (ou Gaussiana) é uma das distribuições mais importantes em estatística. Ela é simétrica em torno da média e é caracterizada por dois parâmetros: a média (μ) e o desvio padrão (σ).

1. Parâmetros:

- μ : Média da distribuição.
- σ : Desvio padrão da distribuição ($\sigma > 0$).

2. Domínio:

- A variável aleatória X assume valores em todo o conjunto dos números reais:

$$X \in \mathbb{R}.$$

3. Função Densidade de Probabilidade (FDP):

- A densidade de probabilidade de X é dada por:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}.$$

4. Esperança (Valor Esperado):

- O valor esperado de X é a média da distribuição:

$$E(X) = \mu.$$

5. Variância:

- A variância de X é o quadrado do desvio padrão:

$$Var(X) = \sigma^2.$$

6. Aplicações:

- Modelagem de alturas, pesos, notas de provas, entre outros.
- Análise de erros em medições.

7. A Figura 12 ilustra o formato da função densidade de probabilidade de uma variável normal.




Figura 12: Exemplo de distribuição normal: $\mu = 170$, $\sigma = 10$

6.3 Distribuição Exponencial

A **distribuição exponencial** é uma distribuição contínua frequentemente usada para modelar o tempo entre eventos em um processo de Poisson, onde os eventos ocorrem de forma independente a uma taxa constante. Ela é caracterizada por um único parâmetro: a taxa de ocorrência (λ).

1. Parâmetros:

- λ : Taxa de ocorrência dos eventos ($\lambda > 0$).

2. Domínio:

- A variável aleatória X assume valores não negativos:

$$X \in [0, \infty).$$

3. Função Densidade de Probabilidade (FDP):

- A densidade de probabilidade de X é dada por:

$$f(x) = \lambda e^{-\lambda x}, \quad x \geq 0.$$

4. Esperança (Valor Esperado):

- O valor esperado de X é o inverso da taxa λ :

$$E(X) = \frac{1}{\lambda}.$$

5. Variância:

- A variância de X é o inverso do quadrado da taxa λ :

$$Var(X) = \frac{1}{\lambda^2}.$$

6. Aplicações:

- Modelagem do tempo entre chegadas em sistemas de filas.
- Tempo de vida de componentes eletrônicos.
- Tempo entre chamadas telefônicas em uma central.

7. A Figura 13 ilustra o formato da função densidade de probabilidade de uma variável exponencial.




Figura 13: Exemplo de distribuição exponencial: $\lambda = 0,5$

6.4 Distribuição Gama

A **distribuição gama** é uma distribuição contínua que generaliza a distribuição exponencial e é amplamente utilizada para modelar tempos de espera, tempos de vida de componentes e processos com múltiplas etapas. Ela é caracterizada por dois parâmetros: o parâmetro de forma (α) e o parâmetro de escala (β).

1. Parâmetros:

- α : Parâmetro de forma ($\alpha > 0$).
- β : Parâmetro de escala ($\beta > 0$).

2. Domínio:

- A variável aleatória X assume valores não negativos:

$$X \in [0, \infty).$$

3. Função Densidade de Probabilidade (FDP):

- A densidade de probabilidade de X é dada por:

$$f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, \quad \text{para } x \geq 0,$$

onde $\Gamma(\alpha)$ é a função gama, definida como:

$$\Gamma(\alpha) = \int_0^{\infty} t^{\alpha-1} e^{-t} dt.$$

4. Esperança (Valor Esperado):

- O valor esperado de X é dado por:

$$E(X) = \frac{\alpha}{\beta}.$$

5. Variância:

- A variância de X é dada por:

$$Var(X) = \frac{\alpha}{\beta^2}.$$

6. Aplicações:

- Modelagem de tempos de vida de componentes eletrônicos.
- Tempos de espera em sistemas com múltiplas etapas.
- Análise de riscos em seguros e finanças.

7. A Figura 14 ilustra o formato da função densidade de probabilidade de uma variável gama.

6.5 Distribuição Beta

A **distribuição beta** é uma distribuição contínua definida no intervalo $[0, 1]$, frequentemente utilizada para modelar proporções, probabilidades ou qualquer variável aleatória cujos valores estejam restritos a um intervalo finito. Ela é caracterizada por dois parâmetros de forma: α e β .

1. Parâmetros:

- α : Parâmetro de forma ($\alpha > 0$).
- β : Parâmetro de escala ($\beta > 0$).

2. Domínio:

- A variável aleatória X assume valores no intervalo $[0, 1]$:

$$X \in [0, 1].$$




Figura 14: Exemplo de distribuição gama: $\alpha = 2, \beta = 1$

3. Função Densidade de Probabilidade (FDP):

- A densidade de probabilidade de X é dada por:

$$f(x) = \frac{x^{\alpha-1}(1-x)^{\beta-1}}{B(\alpha, \beta)}, \text{ para } 0 \leq x \leq 1,$$

onde $B(\alpha, \beta)$ é a função beta, definida como:

$$B(\alpha, \beta) = \int_0^1 t^{\alpha-1}(1-t)^{\beta-1} dt.$$

4. Esperança (Valor Esperado):

- O valor esperado de X é dado por:

$$E(X) = \frac{\alpha}{\alpha + \beta}.$$

5. Variância:

- A variância de X é dada por:

$$Var(X) = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}.$$

6. Aplicações:

- Modelagem de proporções, como a taxa de sucesso em experimentos.
- Análise de dados em estudos de confiabilidade.
- Inferência bayesiana, como distribuição a priori para probabilidades.

7. A Figura 15 ilustra o formato da função densidade de probabilidade de uma variável beta.




Figura 15: Exemplo de distribuição beta: $\alpha = 2, \beta = 5$

7 Considerações Finais

Nesta nota de aula, exploramos os conceitos fundamentais das variáveis aleatórias, tanto discretas quanto contínuas, e suas principais distribuições de probabilidade. As variáveis aleatórias discretas, como a uniforme, binomial e Poisson, são essenciais para modelar fenômenos com resultados contáveis, enquanto as variáveis contínuas, como a normal, exponencial e beta, permitem a análise de fenômenos com resultados em intervalos contínuos.

Através das funções de probabilidade (FMP) e densidade de probabilidade (FDP), bem como das funções de distribuição acumulada (FDA), foi possível descrever o comportamento dessas variáveis e calcular probabilidades associadas a eventos de interesse. Além disso, conceitos como esperança e variância fornecem medidas importantes para entender a tendência central e a dispersão das distribuições.

As aplicações práticas dessas distribuições são vastas, desde a modelagem de tempos de espera e taxas de ocorrência até a análise de dados em engenharia, finanças e ciências

naturais. Compreender essas ferramentas é fundamental para a análise estatística e a tomada de decisões baseadas em dados.

As referências, no final desta *Nota de Aula*, contêm os principais títulos utilizados na sua elaboração.

Referências

ALENCAR, M. S. de. *Probabilidade e processos estocásticos*. 1a. ed. São Paulo: Érica, 2008.

CHWIF, L.; MEDINA, A. C. *Modelagem e simulação de eventos discretos: teoria & prática*. 2a. ed. São Paulo: Ed. dos autores, 2006.

DANTAS, C. A. B. *Probabilidade: um curso introdutório*. 2a. ed. São Paulo: Editora da USP, 2000.

DINIZ, M. C.; MELO, F. R. *Probabilidade na prática utilizando a Linguagem Python*. 1a. ed. Rio de Janeiro: LTC, 2024.

FARIAS, A. M. L. de. *Probabilidade e estatística*. 1a. ed. Rio de Janeiro: Fundação CECIERJ, 2010.

FILHO, C. P. *Introdução à simulação de sistemas*. 1a. ed. Campinas: Editora da Unicamp, 1995.

HUNT, J. *A Beginners Guide to Python3 Programming*. 1a. ed. Cham: Springer, 2020.

MARCONTE, G. A. B. *Matemática com Python: um guia prático*. 1a. ed. São Paulo: Novatec, 2018.

MATTHES, E. *Curso intensivo de Python: uma introdução prática e baseada em projetos à programação*. 3a. ed. São Paulo: Novatec, 2023.

MENEZES, N. N. C. *Introdução à Programação com Python: algoritmos e lógica de programação para iniciantes*. 1a. ed. São Paulo: Novatec, 2010.