

Validação do Conjunto de Dados - Parte II

ECOS04 - Simulação e Avaliação de Desempenho

Edmilson Marmo Moreira
edmarmo@unifei.edu.br

Universidade Federal de Itajubá - UNIFEI
Instituto de Engenharia de Sistemas e Tecnologias da Informação - IESTI

Objetivos:

- aplicar o teste do qui-quadrado em diferentes distribuições;
- compreender como calcular frequências esperadas não uniformes;
- estimar parâmetros a partir dos dados;
- utilizar Python para geração de dados aleatórios;
- avaliar a aderência de dados a modelos probabilísticos.

Validação de Modelos

No laboratório anterior, os dados foram comparados com uma distribuição uniforme.

Neste laboratório, serão considerados outros modelos probabilísticos:

- distribuição de Poisson;
- distribuição exponencial.

Objetivo: verificar se os dados são compatíveis com esses modelos.

Distribuição de Poisson

A distribuição de Poisson modela o número de ocorrências de eventos em um intervalo.

Exemplos:

- número de chamadas por minuto;
- número de falhas em um sistema;

Parâmetro:

$$\lambda = \text{média dos dados}$$

Teste de Aderência - Poisson

Para aplicar o teste:

- 1 calcular a média dos dados ($\hat{\lambda}$);
- 2 construir as frequências observadas;
- 3 calcular as frequências esperadas:

$$E_i = n \cdot P(X = i)$$

- 4 aplicar o teste do qui-quadrado.

Teste de Aderência - Poisson

Considere um conjunto com $n = 1000$ observações, em que cada valor representa o número de eventos ocorridos em um intervalo.

Deseja-se verificar se os dados são compatíveis com uma **distribuição de Poisson**.

Teste de Aderência - Poisson

Se $X \sim \text{Poisson}(\lambda)$, então:

$$P(X = x) = \frac{e^{-\lambda} \lambda^x}{x!}$$

O parâmetro λ representa a média de ocorrências.

Como, na distribuição de Poisson:

$$E[X] = \lambda$$

pode-se estimar λ a partir dos dados por meio da média amostral:

$$\hat{\lambda} = \bar{x}$$

Observação: a média observada é usada como estimativa para o parâmetro do modelo.

Construção das Classes

A partir dos dados, constrói-se a tabela de frequências observadas.

Exemplo de agrupamento:

0, 1, 2, 3, 4, 5, 6, 7, ≥ 8

Neste caso, temos $k = 9$ categorias.

Observação:

- valores maiores possuem baixa probabilidade;
- suas frequências esperadas podem ser muito pequenas;
- por isso, são agrupados em uma única classe.

Frequências esperadas

Diferente da distribuição uniforme, as frequências esperadas não são iguais.

Para cada categoria x_i , calcula-se:

$$E_i = n \cdot P(X = x_i)$$

onde $P(X = x_i)$ é dado pela distribuição de Poisson com $\lambda = \hat{\lambda}$.

Teste do qui-quadrado

A estatística do teste é dada por:

$$\chi^2 = \sum_{i=1}^k \frac{(f_i - E_i)^2}{E_i}$$

- f_i : frequência observada;
- E_i : frequência esperada (Poisson).

Graus de Liberdade

No teste do qui-quadrado, os graus de liberdade dependem das restrições impostas aos dados.

- As frequências devem somar n (1 restrição);
- O parâmetro λ é estimado pela média (mais 1 restrição).

Assim, o número de graus de liberdade é:

$$gl = k - 2$$

Interpretação: perde-se um grau de liberdade adicional devido à estimação de λ .

Teste do qui-quadrado

Regra de decisão:

- Se $\chi^2 \leq \chi^2_{\text{crítico}}$, não se rejeita H_0 ;
- Se $\chi^2 > \chi^2_{\text{crítico}}$, rejeita-se H_0 .

Geração de Dados - Poisson (1o. Exemplo)

```
import numpy as np
from scipy.stats import chi2, poisson

# Geracao dos dados
dados = np.random.poisson(lam=5, size=1000)

n = len(dados)
alpha = 0.05

# Estimativa de lambda
lambda_estimado = np.mean(dados)
...
```

Geração de Dados - Poisson

```
...  
# Classes: 0,1,2,3,4,5,6,7, >=8  
k = 9  
frequencias = [0] * k  
  
for v in dados:  
    if v >= 8:  
        frequencias[8] += 1  
    else:  
        frequencias[v] += 1
```

Teste do qui-quadrado

```
# Frequencias esperadas
E = []
for i in range(8):
    prob = poisson.pmf(i, lambda_estimado)
    E.append(n * prob)

# Classe >=8
prob_tail = 1 - sum(poisson.pmf(i, lambda_estimado) for i in
                    range(8))
E.append(n * prob_tail)

# Qui-quadrado
chi2_calculado = sum((f - e)**2 / e for f, e in zip(
    frequencias, E))

# Graus de liberdade
gl = k - 2

# Valor critico
chi2_critico = chi2.ppf(1 - alpha, gl)

...
```

Teste do qui-quadrado

```
...
print("Lambda estimado:", lambda_estimado)
print("Frequencias observadas:", frequencias)
print("Frequencias esperadas:", [round(e,2) for e in E])
print("Qui-quadrado:", chi2_calculado)
print("Valor critico:", chi2_critico)

if chi2_calculado <= chi2_critico:
    print("Nao se rejeita H0 (Poisson)")
else:
    print("Rejeita-se H0")
```


Teste do qui-quadrado

Possível saída do Programa:

```
Lambda estimado: 5.078
Frequencias observadas: [6, 36, 74, 148, 164, 180, 144, 92,
    156]
Frequencias esperadas: [6.23, 31.65, 80.35, 136.01, 172.67,
    175.36, 148.41, 107.66, 141.64]
Qui-quadrado: 6.58912097318407
Valor critico: 14.067140449340169
Nao se rejeita H0 (Poisson)
```

Conclusão do Primeiro Exemplo

- As frequências observadas são compatíveis com o modelo;
- O valor de χ^2 é pequeno;

Conclusão: não há evidências para rejeitar H_0 (Poisson).

Segundo Exemplo

Considere agora um novo conjunto de dados.

Deseja-se verificar se os dados são compatíveis com uma distribuição de Poisson.

Neste caso, os dados não seguem uma distribuição de Poisson.

Frequências Observadas

$$f = (50, 60, 70, 80, 90, 110, 120, 140, 280)$$

Distribuição mais espalhada do que o esperado para uma Poisson.

Interpretação dos Índices

Neste contexto, aparecem dois índices diferentes:

- Na distribuição de Poisson:

$$P(X = x)$$

o valor x representa o **número de ocorrências**;

- No teste do qui-quadrado:

$$\chi^2 = \sum_{i=1}^k \frac{(f_i - E_i)^2}{E_i}$$

o índice i representa a **classe**.

Importante: o índice do somatório não representa diretamente o valor da variável.

Cálculo das Frequências Esperadas

Para cada valor i , calcula-se:

$$E_i = n \cdot P(X = i)$$

Com $\lambda \approx 6$ e $n = 1000$, por exemplo:

$$E_2 = 1000 \cdot \frac{e^{-6} \cdot 6^2}{2!} \approx 44,6$$

Interpretação: espera-se aproximadamente 45 ocorrências do valor 2.

Frequências Esperadas

Com $\hat{\lambda} \approx 6$ e $n = 1000$, obtêm-se:

$$E = (2.5, 14.9, 44.6, 89.2, 133.9, 160.6, 160.6, 137.7, 256)$$

Observação:

- valores pequenos no início;
- maior concentração próxima à média;
- cauda agrupada em ≥ 8 .

Cálculo do Qui-Quadrado

$$\chi^2 = \sum_{i=1}^k \frac{(f_i - E_i)^2}{E_i}$$

Substituindo alguns termos:

$$\chi^2 \approx \frac{(50 - 2.5)^2}{2.5} + \frac{(60 - 14.9)^2}{14.9} + \frac{(70 - 44.6)^2}{44.6} + \dots$$

Observação: várias diferenças são muito grandes.

Segundo Exemplo em Python

```
import math
from scipy.stats import chi2

f = [50, 60, 70, 80, 90, 110, 120, 140, 280]
n = sum(f)
k = len(f)
alpha = 0.05
lambda_estimado = 6

E = []
for i in range(8):
    prob = math.exp(-lambda_estimado) * lambda_estimado**i /
        math.factorial(i)
    E.append(n * prob)

prob_tail = 1 - sum(E) / n
E.append(n * prob_tail)
```

Segundo Exemplo em Python

```
chi2_calculado = sum((fo - fe)**2 / fe for fo, fe in zip(f,
    E))
gl = k - 2
chi2_critico = chi2.ppf(1 - alpha, gl)

print("Frequencias esperadas:", [round(e, 2) for e in E])
print("Qui-quadrado:", round(chi2_calculado, 2))
print("Valor critico:", round(chi2_critico, 2))

if chi2_calculado > chi2_critico:
    print("Rejeita-se H0")
else:
    print("Nao se rejeita H0")
```

Segundo Exemplo em Python

Saída do Programa:

```
Frequencias esperadas: [2.48, 14.87, 44.62, 89.24, 133.85,  
    160.62, 160.62, 137.68, 256.02]  
Qui-quadrado: 1106.26  
Valor critico: 14.07  
Rejeita-se H0
```

Resultado

Após o cálculo completo, obtém-se:

$$\chi^2 \approx 1106.3$$

Para $k = 9$ classes e $gl = k - 2 = 7$, com nível de significância de 5%:

$$\chi_{0,05;7}^2 \approx 14,07$$

Como:

$$1106.3 \gg 14.07$$

rejeita-se H_0 . Os dados não são compatíveis com uma distribuição de Poisson.

Atividade prática

Nesta atividade, será analisado um conjunto de dados gerado por um programa.

O objetivo é verificar se os dados produzidos são compatíveis com uma **distribuição de Poisson**.

Para isso, deverão ser aplicados os procedimentos de análise e o teste do qui-quadrado.

Atividade prática

Geração dos Dados:

```
import numpy as np

dados = np.concatenate([
    np.random.poisson(lam=2, size=500),
    np.random.poisson(lam=10, size=500)
])
```

O conjunto de dados contém 1000 observações.

Crie um programa em Python para:

- calcular a média dos dados ($\hat{\lambda}$);
- construir a tabela de frequências observadas;
- definir as classes (incluindo o agrupamento da cauda);
- calcular as frequências esperadas assumindo uma distribuição de Poisson;
- aplicar o teste do qui-quadrado;
- comparar o valor obtido com o valor crítico;
- concluir se a hipótese de distribuição de Poisson deve ser rejeitada.

Entrega:

- enviar um único arquivo contendo o código;
- incluir, ao final do arquivo, a saída do programa como comentário;
- justificar a conclusão com base nos resultados obtidos.

Variáveis Aleatórias Contínuas

Variáveis Aleatórias Contínuas

Diferentemente do caso discreto, onde a variável assume valores isolados, uma **variável aleatória contínua** pode assumir infinitos valores em um intervalo.

Exemplos:

- tempo de espera;
- tempo entre chegadas.

Probabilidade em Variáveis Contínuas


Uma característica fundamental:

$$P(X = x) = 0$$

A probabilidade é definida em intervalos:

$$P(a \leq X \leq b) = \int_a^b f_X(x) dx$$

Interpretação: probabilidade = área sob a curva.



Função Densidade de Probabilidade

Exemplo: Considere $f(x) = 2x$, para $0 \leq x \leq 1$.

Qual a probabilidade de $X < \frac{1}{3}$?

$$P\left(X < \frac{1}{3}\right) = \int_0^{1/3} 2x \, dx$$

Variáveis Aleatórias Contínuas

$$P(X < \frac{1}{3}) = \int_0^{\frac{1}{3}} f(x)dx$$

Então:

$$P(X < \frac{1}{3}) = \int_0^{\frac{1}{3}} f(x)dx = \int_0^{\frac{1}{3}} 2x dx = 2 \int_0^{\frac{1}{3}} x dx$$

Calculando a integral:

$$= 2 \left[\frac{x^2}{2} \right]_0^{\frac{1}{3}} = \left(\frac{1}{3} \right)^2 - 0^2 = \frac{1}{9}$$


Interpretação: área sob a curva no intervalo $[0, 1/3]$.

Função de Distribuição Acumulada

A função acumulada é definida por:

$$F_X(x) = P(X \leq x)$$

Interpretação: área sob a curva de densidade até o ponto x .



Função de Distribuição Acumulada

A probabilidade de um intervalo pode ser obtida por:

$$P(a \leq X < b) = P(X \leq b) - P(X \leq a)$$

$$P(a \leq X < b) = F_X(b) - F_X(a)$$

Interpretação: diferença entre áreas acumuladas.

Exemplo

No exemplo anterior, obteve-se:

$$F_X(x) = x^2$$

Agora, usando a função acumulada:

$$P\left(X < \frac{1}{3}\right) = F_X\left(\frac{1}{3}\right) = \frac{1}{9}$$

Observação: a integral já foi incorporada em $F_X(x)$, permitindo calcular probabilidades de forma direta.

Frequência Esperada em Variáveis Contínuas

No caso discreto:

$$E_i = n \cdot P(X = x_i)$$

No caso contínuo:

$$E_i = n \cdot P(a_i \leq X < b_i)$$

$$E_i = n \cdot (F_X(b_i) - F_X(a_i))$$

Resumo:

frequência esperada = total de dados $\times$ probabilidade do intervalo

Exemplo: Distribuição Exponencial

A **distribuição exponencial** modela o **tempo entre eventos**.

Função densidade de probabilidade:

$$f_X(x) = \lambda e^{-\lambda x}, \quad x \geq 0$$

Função de distribuição acumulada:

$$F_X(x) = 1 - e^{-\lambda x}$$

Estimativa do parâmetro:

$$\hat{\lambda} = \frac{1}{\bar{x}}$$

Objetivo: verificar se os dados são compatíveis com esse modelo.

Exemplo: Distribuição Exponencial

Código para gerar os dados do exemplo:

```
import numpy as np

# Gerador de numeros aleatorios (forma tradicional do NumPy)
np.random.seed(42)

# Dados exponenciais
dados = np.random.exponential(scale=2, size=1000)
```

Observação: $\text{scale} = 2 \Rightarrow \lambda = 0.5$

Estimativa do Parâmetro

Calcula-se a média dos dados:

$$\bar{x} \approx 2$$

Estimativa:

$$\hat{\lambda} = \frac{1}{\bar{x}} \approx 0.5$$

Construção das Classes

Para garantir frequências esperadas adequadas, utilizam-se classes equiprováveis.

Intervalos definidos a partir da distribuição exponencial:

$$[0, 0.45), [0.45, 1.02), [1.02, 1.83), [1.83, 3.22), [3.22, \infty)$$

Número de classes:

$$k = 5$$

Observação: os intervalos foram escolhidos de forma que cada um tenha aproximadamente a mesma probabilidade (20%).

Construção dos Intervalos

Deseja-se dividir a distribuição em classes com a mesma probabilidade:

$$P = 0.2 \quad (20\% \text{ em cada intervalo})$$

Utiliza-se a função acumulada da exponencial:

$$F_X(x) = 1 - e^{-\lambda x}$$

Para encontrar os limites, resolve-se:

$$F_X(x) = p$$

$$x = -\frac{\ln(1 - p)}{\lambda}$$

Exemplo:

$$p = 0.2 \Rightarrow x \approx 0.45$$

Intervalos Equiprováveis

Aplicando a fórmula para:

$$p = 0.2, 0.4, 0.6, 0.8$$

Obtêm-se os pontos:

$$0.45, 1.02, 1.83, 3.22$$

Assim, definem-se os intervalos:

$$[0, 0.45), [0.45, 1.02), [1.02, 1.83), [1.83, 3.22), [3.22, \infty)$$

Cada intervalo contém aproximadamente 20% dos dados.

Frequências Observadas

A partir dos dados gerados, obtém-se:

$$f = (211, 203, 177, 214, 195)$$

Observação: pequenas variações são esperadas.

Frequências Esperadas

Como os intervalos são equiprováveis:

$$P = 0.2$$

$$E_i = n \cdot P = 1000 \cdot 0.2 = 200$$

$$E = (200, 200, 200, 200, 200)$$

Cálculo do Qui-Quadrado

$$\chi^2 = \sum_{i=1}^k \frac{(f_i - E_i)^2}{E_i}$$

$$\chi^2 \approx 4,4$$

Interpretação: diferenças pequenas entre frequências observadas e esperadas.

Resultado

Graus de liberdade:

$$gl = k - 2 = 3$$

$$\chi^2_{0.05;3} \approx 7.81$$

Como:

$$4.4 < 7.81$$

não se rejeita H_0 .

Conclusão

Os dados são compatíveis com uma distribuição exponencial.

Observação:

- as frequências estão equilibradas;
- não há evidências para rejeitar o modelo exponencial.

Implementação em Python

```
import numpy as np
from scipy.stats import chi2

# Geracao dos dados
np.random.seed(42)
dados = np.random.exponential(scale=2, size=1000)

n = len(dados)
alpha = 0.05

# Estimativa de lambda
media = np.mean(dados)
lambda_estimado = 1 / media

print("Media:", round(media, 3))
print("Lambda estimado:", round(lambda_estimado, 3))
```

Implementação em Python

```
# Intervalos equiprovaveis (aprox. 20%)
intervalos = [0, 0.45, 1.02, 1.83, 3.22, np.inf]

k = 5
frequencias = [0] * k

# Contagem das frequencias observadas
for v in dados:
    for i in range(k):
        if intervalos[i] <= v < intervalos[i+1]:
            frequencias[i] += 1
            break

print("Frequencias observadas:", frequencias)
```

Implementação em Python

```
# Frequencias esperadas (equiprovaveis)
E = [n / k] * k

# Calculo do qui-quadrado
chi2_calculado = sum((f - e)**2 / e for f, e in zip(
    frequencias, E))

# Graus de liberdade
gl = k - 2

# Valor critico
chi2_critico = chi2.ppf(1 - alpha, gl)

print("Qui-quadrado:", round(chi2_calculado, 2))
print("Valor critico:", round(chi2_critico, 2))
```

Resultado do Programa

```
if chi2_calculado <= chi2_critico:
    print("Nao se rejeita H0 (distribuicao exponencial)")
else:
    print("Rejeita-se H0")
```

Validação do Conjunto de Dados - Parte II

ECOS04 - Simulação e Avaliação de Desempenho

Edmilson Marmo Moreira
edmarmo@unifei.edu.br

Universidade Federal de Itajubá - UNIFEI
Instituto de Engenharia de Sistemas e Tecnologias da Informação - IESTI